CHINA · TECNOLOGÍA · FRONTERA DE IA

INTELIGENCIA ARTIFICIAL CHINA

DeepSeek · Qwen · Agentes
Arquitecturas, eficiencia y aplicaciones

Sergio Gevatschnaider



BLOQUE 01 / 07

El ecosistema chino de IA

De la investigación al despliegue

¿En qué dimensiones compite China y dónde están sus restricciones?

SERGIO GEVATSCHNAIDER



La nueva competencia no es una carrera única

Capacidad técnica, disponibilidad, infraestructura y adopción son dimensiones distintas.

01

Frontera de modelos

Razonamiento, código, multimodalidad y robustez: cada capacidad requiere una prueba diferente.

02

Ecosistema abierto

Pesos accesibles, herramientas, comunidades, despliegue y adaptación especializada.

03

Infraestructura

Cómputo, memorias, redes, datos, energía, talento y software.

04

Adopción

Integración empresarial, productividad real, gobernanza y seguridad.

La potencia económica de la IA depende tanto de la tecnología como de su difusión.

Fuentes: Stanford AI Index 2026 · Documentación oficial

IA Index 2026: evidencia comparada

Contar lanzamientos no equivale a medir liderazgo agregado.

59

Modelos notables de EE. UU. identificados en 2025

35

Modelos notables con afiliación china en 2025

Los valores no implican equivalencia de calidad, costo o rendimiento entre familias.

Datos de 2025 publicados en AI Index 2026; la atribución por afiliación puede superponerse.

Fuentes: Stanford AI Index 2026 · Documentación oficial

Mapa del ecosistema de IA chino

Empresas, investigación, plataformas y aplicaciones forman un sistema heterogéneo.

01

DeepSeek

Arquitectura eficiente y modelos de razonamiento.

02

Alibaba / Qwen

Familia de modelos abiertos, nube y agentes multimodales.

03

Baidu / ERNIE

Modelos, servicios de búsqueda y ecosistemas empresariales.

04

Tencent / Hunyuan

Aplicaciones, servicios y plataforma de IA.

Evitar describir a China como una única entidad empresarial.

Fuentes: Stanford AI Index 2026 · Documentación oficial

De los laboratorios a las industrias

El valor se captura cuando la IA resuelve actividades medibles.



La adopción requiere rediseñar procesos, no solo contratar una API.

Fuentes: Stanford AI Index 2026 · Documentación oficial

Fortalezas y restricciones

La eficiencia algorítmica responde parcialmente a limitaciones de infraestructura.

A

FORTALEZAS

Talento técnico, manufactura, demanda, ecosistemas de software abierto, experimentación y velocidad de integración.

B

RESTRICCIONES

Disponibilidad de chips avanzados, memorias, infraestructura, seguridad, calidad de datos y acceso a mercados.

Capacidad de modelo ≠ disponibilidad de hardware ≠ productividad.

Fuentes: Stanford AI Index 2026 · Documentación oficial

BLOQUE 02 / 07

La arquitectura de los modelos

Cómo aprenden, procesan y generan

¿Dónde se sitúa la innovación detrás de las marcas?

SERGIO GEVATSCHNAIDER



Del texto a los tokens

La tokenización y los embeddings cambian lenguaje por representación numérica.



No confundir token, palabra y parámetro.

Fuentes: Transformers · IBM MoE · documentación de Qwen y DeepSeek

Transformer: atención y contexto

La atención conecta posiciones y construye representaciones dependientes del contexto.

01

Consulta (Q)

Qué información requiere la posición actual.

02

Clave (K)

Cómo se identifica cada posición potencialmente relevante.

03

Valor (V)

Qué contenido se combina en la representación.

04

Enmascarado

Evita que el decodificador vea tokens futuros al predecir.

El costo de atención depende de longitud y arquitectura.

Fuentes: Transformers · IBM MoE · documentación de Qwen y DeepSeek

Dense frente a Mixture of Experts

Capacidad total y trabajo activado son magnitudes diferentes.

01

DENSO

Los bloques densos aplican sus parámetros a cada token. Escalamiento directo de cómputo con tamaño del bloque.

02

MoE

Un router dirige cada token a un subconjunto de expertos. Mayor capacidad potencial con cómputo escaso por token.

MoE exige balanceo de carga y comunicación entre dispositivos.

Fuentes: Transformers · IBM MoE · documentación de Qwen y DeepSeek

Cómo funciona el router MoE

La elección top-k convierte un problema de asignación en una arquitectura computacional.



Esquema top-2 ilustrativo. Los expertos son subredes aprendidas, sin roles temáticos garantizados.

Fuentes: Transformers · IBM MoE · documentación de Qwen y DeepSeek

Multimodalidad y acción

Un agente multimodal integra percepción, lenguaje, herramientas y respuestas.

01

Imagen / video

Representaciones visuales y temporales.

02

Texto / código

Razonamiento y generación simbólica.

03

Herramientas

APIs, archivos, navegación y ejecución restringida.

04

Acción

Interfaces, automatizaciones y resultados observables.

Un modelo multimodal no es necesariamente un agente autónomo.

Fuentes: Transformers · IBM MoE · documentación de Qwen y DeepSeek

BLOQUE 03 / 07

DeepSeek: eficiencia y razonamiento

El diseño importa tanto como la escala

¿Qué aportan V3 y R1 y qué no prueban sus resultados?

SERGIO GEVATSCHNAIDER



DeepSeek-V3: arquitectura escasa

El reporte original documenta un gran modelo MoE con activación reducida.

671 B

Parámetros totales reportados

37 B

Parámetros activados por token

Los valores no implican equivalencia de calidad, costo o rendimiento entre familias.

Cifras de DeepSeek-V3 (reporte de diciembre 2024); no extrapolar a versiones posteriores.

Fuentes: DeepSeek-V3 Technical Report · Nature (R1)

DeepSeek-V3: innovaciones clave

La eficiencia proviene de varias decisiones de arquitectura y entrenamiento.

01

MLA

Multi-head Latent Attention: compresión de estados K/V.

02

DeepSeekMoE

Especialización y activación selectiva de expertos.

03

Balanceo

Métodos para distribuir tráfico de tokens.

04

MTP

Objetivo de predicción de múltiples tokens en entrenamiento.

El diseño se evalúa como sistema, no como una cifra de parámetros.

Fuentes: DeepSeek-V3 Technical Report · Nature (R1)

El costo no es una cifra universal

Horas de GPU publicadas no equivalen al costo integral de un proyecto.

A

LO REPORTADO

El informe V3 declara 2,788 millones de horas de GPU H800 para el entrenamiento completo descrito.

B

LO NO INCLUIDO EN ESA CIFRA

Investigación previa, exploración de arquitectura, datos, personal, infraestructura y otras fases operativas.

Evitar presentar costos estimados de entrenamiento como costo total auditado.

Fuentes: DeepSeek-V3 Technical Report · Nature (R1)

DeepSeek-R1: aprendizaje por refuerzo

El razonamiento se puede reforzar mediante recompensas sobre tareas verificables.



Iteración del entrenamiento

No equivale a pensamiento humano ni garantiza veracidad.

Fuentes: DeepSeek-V3 Technical Report · Nature (R1)

R1-Zero, R1 y destilación

Distinguir experimento de RL, ajuste práctico y transferencia de capacidades.

01

R1-Zero

RL extensivo sin SFT inicial; emergen conductas útiles y problemas de legibilidad.

02

R1

Fases de arranque en frío, supervisión y RL para mejorar utilidad y claridad.

03

Destilación

Modelos menores entrenados a partir de trazas / salidas de sistemas mayores.

04

Cautela

Evaluar longitud, costo, errores, sesgos y seguridad por tarea.

Nature 2025 documenta el trabajo de DeepSeek-R1.

Fuentes: DeepSeek-V3 Technical Report · Nature (R1)

BLOQUE 04 / 07

Qwen: una familia de arquitecturas

Modelos abiertos y capacidades multimodales

¿Qué cambia entre Qwen3 y Qwen3.5?

SERGIO GEVATSCHNAIDER



Qwen3: pensar o responder

Los modos híbridos permiten administrar deliberación y latencia.

01

NO-THINKING

Respuestas directas para solicitudes simples, conversación y tareas de baja complejidad.

02

THINKING

Mayor procesamiento deliberativo para razonamiento, código y cadenas de decisiones.

El modo adecuado depende de dificultad, presupuesto y fiabilidad.

Fuentes: Alibaba Group · Qwen Team, 2025–2026

Qwen3.5: arquitectura multimodal

El anuncio de 2026 presenta una combinación de atención híbrida y expertos dispersos.

397 B

Parámetros totales del modelo anunciado

17 B

Parámetros activos por paso de propagación

Los valores no implican equivalencia de calidad, costo o rendimiento entre familias.

Qwen3.5-397B-A17B: cifras declaradas por Alibaba (febrero 2026).

Fuentes: Alibaba Group · Qwen Team, 2025–2026

¿Por qué atención híbrida?

Las arquitecturas buscan balancear contexto, memoria y rendimiento.

01

Atención estándar

Interacciones ricas entre tokens con costo de contexto creciente.

02

Atención lineal

Reduce ciertos costos mediante estados recurrentes o formulaciones alternativas.

03

Combinación

Intercala bloques para preservar capacidades y eficiencia.

04

Condiciones

Los resultados cambian por hardware, longitud y cargas de trabajo.

No hay una superioridad universal independiente de la tarea.

Fuentes: Alibaba Group · Qwen Team, 2025–2026

Agentes nativos y percepción multimodal

Texto e imagen se integran con decisiones y herramientas.



Agencia requiere orquestación y límites, no solo arquitectura multimodal.

Fuentes: Alibaba Group · Qwen Team, 2025–2026

Comparación académica: DeepSeek y Qwen

Comparar por objetivos de diseño y documentación, no por marketing.

A

DEEPSEEK

Énfasis en eficiencia arquitectónica MoE/MLA y desarrollo de razonamiento RL, especialmente V3 y R1.

B

QWEN

Familia amplia, modos híbridos de razonamiento, variantes densas/MoE y modelos multimodales con enfoque agentivo.

La evaluación válida exige misma fecha, benchmark, hardware y protocolo.

Fuentes: Alibaba Group · Qwen Team, 2025–2026

BLOQUE 05 / 07

Razonamiento, optimización y costo

De la probabilidad a la verificación

¿Cuándo merece la pena pensar más y cuándo conviene una herramienta?

SERGIO GEVATSCHNAIDER



Entrenar no es inferir

El gasto de entrenamiento no describe el costo marginal de cada consulta.

01

ENTRENAMIENTO

Actualización de pesos con grandes conjuntos de datos, optimizador, infraestructura y experimentación.

02

INFERENCIA

Generación de tokens; costos de cómputo, memoria, latencia, concurrencia y salida.

Un sistema barato por consulta puede ser caro por tarea completada.

Fuentes: Nature R1 · Qwen3 / Qwen3.5 · Stanford AI Index

Presupuesto de razonamiento

Más tokens de deliberación pueden mejorar tareas difíciles y encarecer su ejecución.

01
Calidad

Tasa de éxito validado contra criterios independientes.

02
Latencia

Tiempo hasta solución aceptada, no solo primeros tokens.

03
Consumo

Tokens, GPU, memoria, búsquedas y reintentos.

04
Riesgo

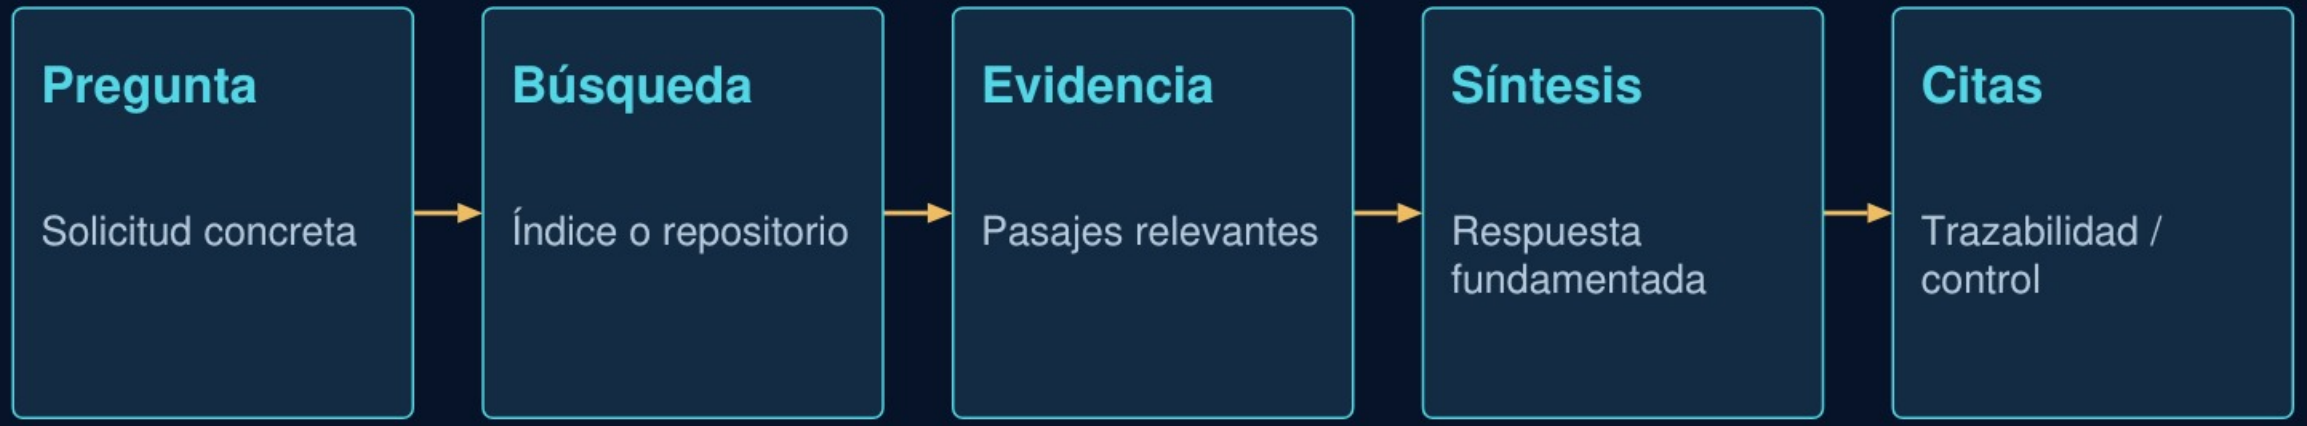
Errores prolongados, bucles y falsa confianza.

El simulador ajusta dificultad y presupuesto en un modelo conceptual.

Fuentes: Nature R1 · Qwen3 / Qwen3.5 · Stanford AI Index

RAG: recuperar antes de responder

La recuperación enlaza la generación con documentos y fuentes verificables.



Un documento recuperado puede contener instrucciones maliciosas.

Fuentes: Nature R1 · Qwen3 / Qwen3.5 · Stanford AI Index

Fine-tuning, RAG y herramientas

Tres soluciones distintas para problemas distintos.

01

Fine-tuning

Adaptar estilo, formato y patrones de tarea.

02

RAG

Consultar conocimiento variable y rastreable.

03

Tool use

Realizar operaciones y consultar estados externos.

04

Reglas

Garantizar restricciones donde una política exacta es preferible.

Elegir según necesidad de actualización, seguridad y costo.

Fuentes: Nature R1 · Qwen3 / Qwen3.5 · Stanford AI Index

Economía de inferencia

Optimizar costo por tarea bien resuelta, no solo precio por millón de tokens.

01

Coste efectivo

Modelo + herramientas + verificación + reintentos.

02

Rendimiento

Tareas correctas por unidad de tiempo / presupuesto.

03

Escalabilidad

Concurrencia, caché, cuantización y batching.

04

Gobernanza

Privacidad, auditoría, licencias y procesos.

Una decisión de arquitectura es también una decisión organizacional.

Fuentes: Nature R1 · Qwen3 / Qwen3.5 · Stanford AI Index

BLOQUE 06 / 07

Agentes y sistemas multiagente

De responder preguntas a ejecutar flujos

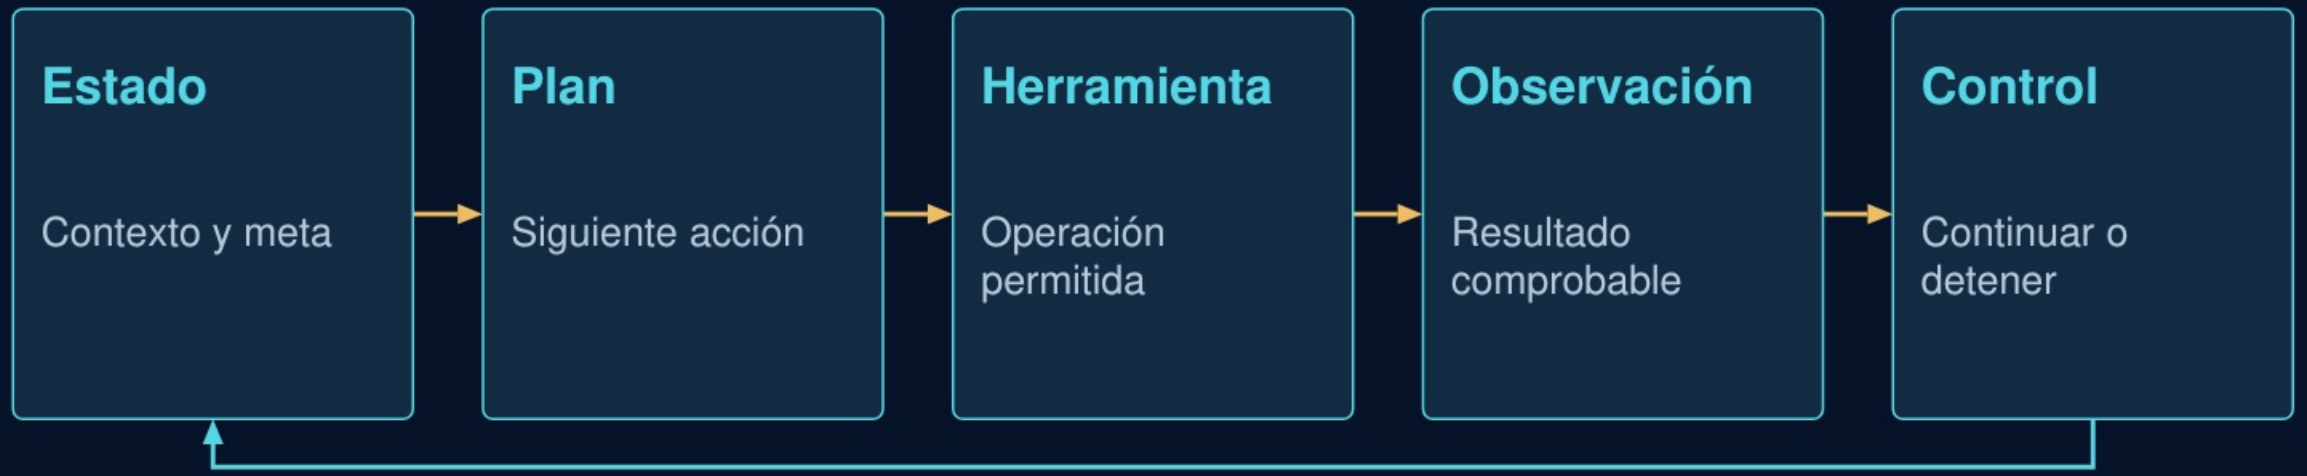
¿Cómo se transforma un modelo en una arquitectura operativa?

SERGIO GEVATSCHNAIDER



Qué es un agente de IA

Un bucle que observa, decide, usa herramientas y verifica el estado.



Autonomía no es ausencia de supervisión.

Fuentes: Hugging Face Agents Course · Stanford · publicaciones de evaluación

Arquitecturas de coordinación

La especialización introduce sobrecostos y nuevas superficies de fallo.

01

Agente único

Sencillo de operar, rápido para tareas acotadas.

02

Secuencial

Cadena de especialidades con entrega explícita.

03

Paralelo

Tareas independientes ejecutadas simultáneamente.

04

Jerárquico

Supervisor distribuye y valida la ejecución.

Preferir menor complejidad compatible con la tarea.

Fuentes: Hugging Face Agents Course · Stanford · publicaciones de evaluación

El agente investigador

Una investigación reproducible necesita rutas y trazabilidad.

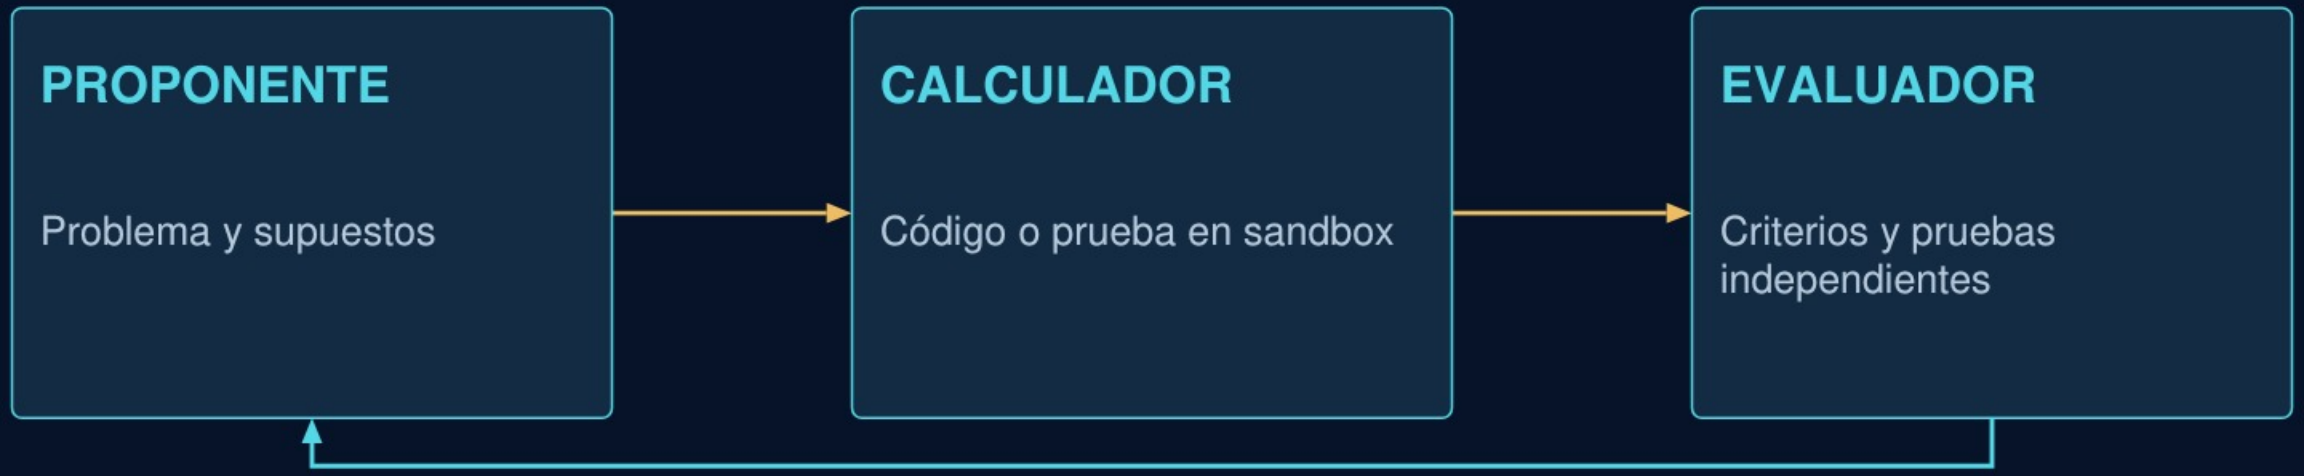


Las citas falsas son un modo de fallo a medir explícitamente.

Fuentes: Hugging Face Agents Course · Stanford · publicaciones de evaluación

Agente matemático y evaluador

Separar propuesta, cálculo y verificación reduce errores ocultos.



Si falla: revisar la propuesta

SUPERVISOR: límites de recursos y reintentos

Un evaluador del mismo modelo puede compartir sesgos. Incluir pruebas deterministas.

Fuentes: Hugging Face Agents Course · Stanford · publicaciones de evaluación

MCP, herramientas y permisos

Las interfaces estructuradas facilitan conexión; no eliminan riesgos.

01

Esquema

Entradas tipadas y salidas comprensibles.

02

Permisos

Mínimo privilegio y aprobación en acciones sensibles.

03

Estado

Registros de cada acción y resultados.

04

Sandbox

Aislamiento, límites de recursos y reproducibilidad.

No dejar que texto recuperado se convierta en instrucción privilegiada.

Fuentes: Hugging Face Agents Course · Stanford · publicaciones de evaluación

BLOQUE 07 / 07

Evaluación, seguridad y despliegue

De la demostración a un sistema confiable

¿Cómo probar capacidad, costo y seguridad sin confundir métricas?

SERGIO GEVATSCHNAIDER



Benchmarks: qué miden y qué no

Una mejora en un benchmark no constituye garantía en casos reales.

01
Capacidad

Conjunto de tareas, criterios y protocolos.

02
Contaminación

Riesgo de ejemplos vistos en entrenamiento.

03
Generalización

Pruebas nuevas, distribución cambiante.

04
Métrica final

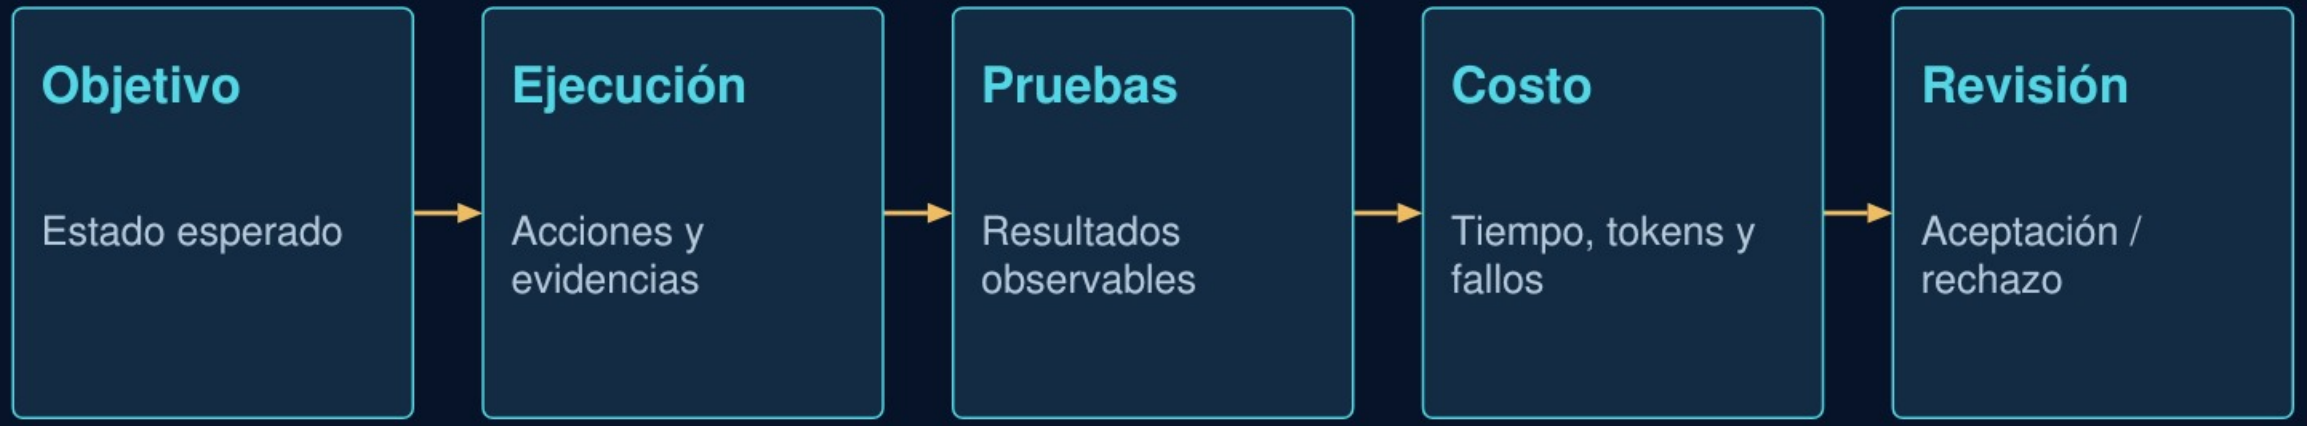
Exactitud, tasa de éxito, robustez y costo.

Registrar versión, fecha y condiciones de ejecución.

Fuentes: Stanford AI Index 2026 · GAIA · OSWorld · OWASP

Evaluar agentes es evaluar trayectorias

Medir el proceso y la ejecución, no solo la respuesta final.



Benchmarks como GAIA u OSWorld proponen tareas con herramientas.

Fuentes: Stanford AI Index 2026 · GAIA · OSWorld · OWASP

Seguridad: inyección y acciones

Instrucciones hostiles pueden viajar dentro de documentos o resultados.

01

Prompt injection

Fuentes de menor confianza intentan alterar el plan.

02

Exfiltración

Datos sensibles enviados a destinos no autorizados.

03

Herramientas

Acciones con permisos excesivos.

04

Defensas

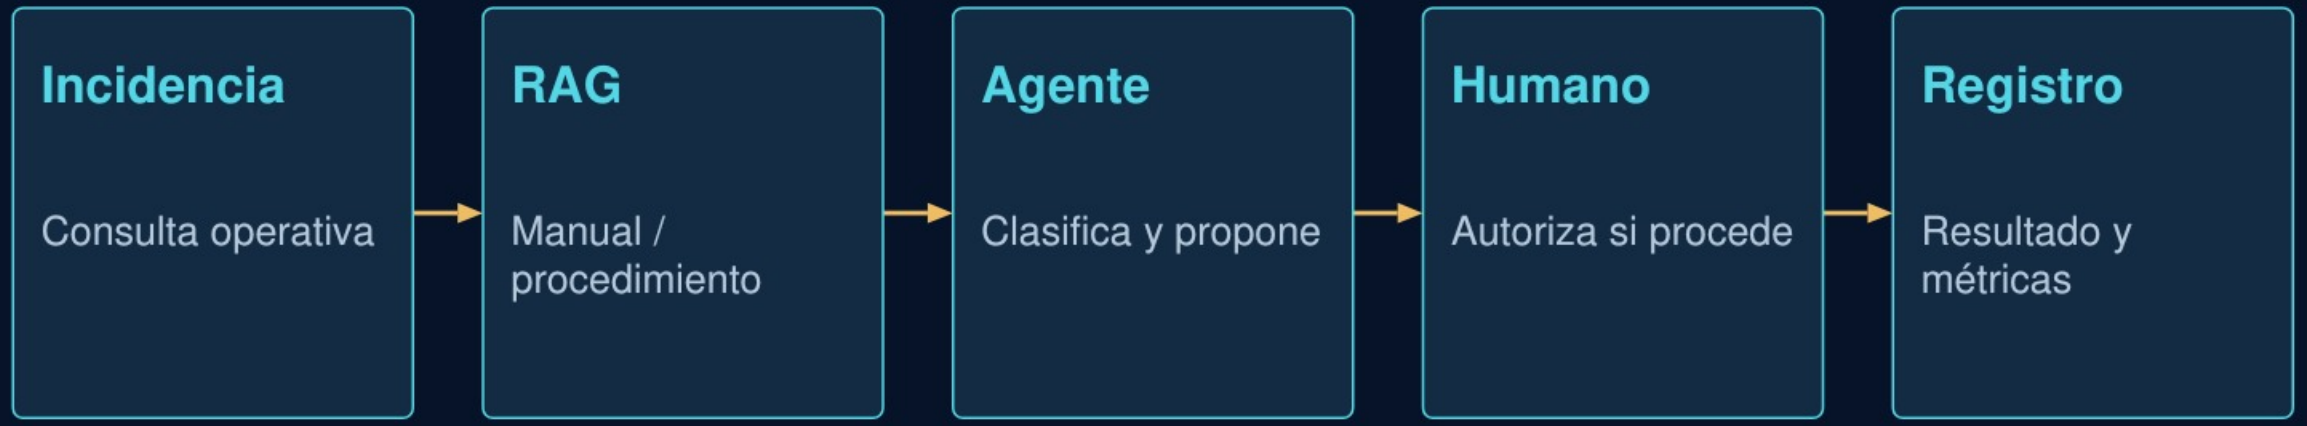
Aislamiento, validación, registros y confirmación.

El filtrado de texto por sí solo no garantiza protección.

Fuentes: Stanford AI Index 2026 · GAIA · OSWorld · OWASP

Caso aplicado: atención industrial

Agentes con fuentes, reglas, revisión humana y retorno medible.



El caso es un diseño conceptual, no una implementación real.

Fuentes: Stanford AI Index 2026 · GAIA · OSWorld · OWASP

Diseño de adopción responsable

Un programa serio une rendimiento técnico con economía institucional.

01

Piloto

Alcance estrecho y datos representativos.

02

Evaluación

Comparación frente a base humana o regla simple.

03

Gobierno

Privacidad, derechos y permisos.

04

Escala

Capacidad, soporte y seguimiento continuo.

La pregunta relevante: ¿qué procesos cambian de verdad?

Fuentes: Stanford AI Index 2026 · GAIA · OSWorld · OWASP

CONCLUSIÓN · CHINA Y LA FRONTERA DE LA IA

La frontera no es solo un modelo. Es un sistema.

Arquitectura · datos · hardware · agentes · evaluación · instituciones

Sergio Gevatschnaider

